SQL в работе с базами данных. Архитектура БД и оптимизация запросов.

Типы СУБД:

• Файл-серверные: Microsoft Access

Клиент-серверные: MySQL, PostgreSQL...

• Встраиваемые: SQLite

Основные клиент-серверные СУБД:

- MySQL
- PostgreSQL
- Oracle
- MS SQL
- MariaDB

Почему мы будем использовать Postgres:

- Free (Open Source)
- Лучший выбор для изучения: проинсталлировал и «понеслась»!
- «Взрослая» СУБД, хорошо поддерживающая транзакционность из коробки
- Весьма развитой диалект SQL
- В сравнении с MySQL есть свои плюсы и минусы
- В любом случае, 90% возможностей диалекта SQL поддерживаемого PostgreSQL можно без изменений использовать и в др. СУБД

НЕ реляционные СУБД:

- Не реляционные СУБД существовали задолго до реляционных (иерархические, например)
- На смену пришли реляционные (начиная с 1970-х)
- И спустя несколько декад, не реляционные СУБД возродились (расцвет в 2010-х)
- Появилось **NoSQL** движение
- mongoDB одна из наиболее популярных NoSQL-СУБД
- Реляционные СУБД не хуже и не лучше не реляционных СУБД
- У всех видов есть свои преимущества и недостатки

Типы NoSQL Баз Данных:

- Реляционные базы данных
- Key-value базы данных
- Документно-ориентированные базы данных
- Графовые базы данных
- Колоночные базы данных

1. Key-Value БД:

В такой базе хранят данные, которые удобно представить в виде пары ключ-значение. Основное преимущество таких баз — это очень быстрый поиск значения по ключу. При этом значение может содержать какие угодно типы данных.

1. Документно-ориентированные

В документно-ориентированной базе данных единицей хранения является документ (который может быть в формате json, или xml, или в каком-нибудь еще формате). Удобство таких баз в том, что в них быстро и легко записывать любые типы данных, при этом эти данные не обязаны обладать четкой структурой. Минус таких баз в том, что данные в них неудобно анализировать.

1. Графовые

Как следует из названия, в графовой базе данных данные хранятся в виде графов. Данный тип баз удобен, когда надо находить информацию не только о каком-то объекте, но и доставать информации о связах этого объекта с другими.

1. Колоночные

В реляционных базах данных данные записаны в виде строк. Что же касается колоночных баз данных, то тут данные записываются в виде столбцов. Потому поиск данных в колоночной базе данных осуществляется не перебором всех строк, как это происходит в реляционной базе данных, а поиском необходимого значения в тех столбцах таблицы, которые нас интересуют.

Преимущество колоночных баз данных в том, что они могут быстро находить определенные значения в столбцах, которые нас интересуют

Реляционная модель включается в себя несколько важных понятий:

- Сущность например, клиенты, продажи и т.д.
- Таблица отношение
- Отношения между таблицами
- Столбец атрибут или поле
- Строка/запись кортеж
- Индекс
- Результирующий набор результат запроса SQL

Отношения между таблицами определяются с помощью primary key и foreign-key

Primary key — это столбец (или группа столбцов) таблицы, который содержит уникальные значения для каждой строки. На примере выше primary key каждой таблицы я выделила зеленым цветом. То есть, например, в таблице с заказами каждая строка будет описывать отдельный заказ. Не будет 2 строк, которые описывают один и тот же заказ, потому ID заказа будет разный для каждой строки.

Foreign key – это столбец в таблице, который содержит primary key другой таблицы. То есть, таблица с заказами содержит ID клиента, который является primary key в таблице с клиентами, но в таблице с заказами он будет foreign key.

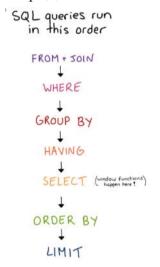
SQL:

- SQL (Structured Query Language, язык структурных запросов) стандартный язык запросов к реляционным базам данных.
- SQL основан на реляционной алгебре.
- Результатом SQL запроса является результирующий набор (как правило таблица)
- DDL (Data Definition Language) CREATE, ALTER, DROP
- DML (Data Manipulation Language) SELECT, INSERT, UPDATE, DELETE
- TCL (Transaction Control Language) COMMIT, ROLLBACK, SAVEPOINT
- DCL (Data Control Language) GRANT, REVOKE, DENY
- ANSI SQL-92
- Различия в процедурных расширениях:
 PL/pgSQL в PostgreSQL, PL/SQL в Oracle, T-SQL в MS SQL

Общая структура запросов:

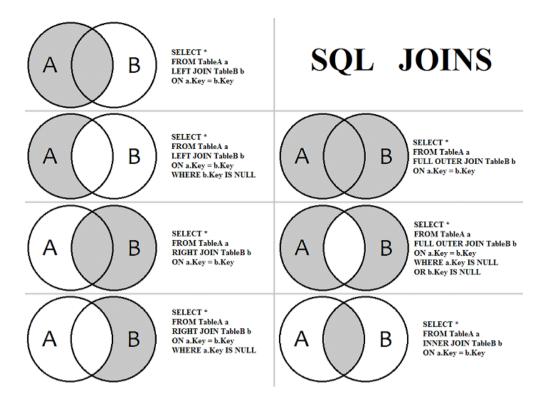
```
SELECT ('столбцы или * для выбора всех столбцов; обязательно')
FROM ('таблица; обязательно')
WHERE ('условие/фильтрация, например, city = 'Moscow'; необязательно')
GROUP BY ('столбец, по которому хотим сгруппировать данные; необязательно')
HAVING ('условие/фильтрация на уровне сгруппированных данных; необязательно')
ORDER BY ('столбец, по которому хотим отсортировать вывод; необязательно')
```

Порядок выполнения SQL запрос:



Типы JOIN:

Как видно, в начале выполняется полный JOIN и выборка все строк из запроса, после которого уже идет отбор и последующие операции

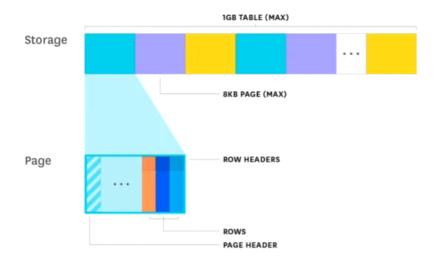


Устройство БД:

Вот главные элементы, которые есть в каждой СУБД, и их функции:

- **Ядро**. Это основа всей системы, которая отвечает за хранение и обработку баз данных. В ядре фиксируются все изменения: добавление, удаление или исправление целых баз и отдельных ячеек.
- -**Процессор, или компилятор.** Обрабатывает запросы к базам данных на внутренних языках и SQL, преобразуя их в нужные команды и передавая результаты.
- **-Программные средства, или утилиты**. С их помощью пользователи вводят запросы, а администраторы баз данных настраивают доступ и другие параметры.
- **-Базы данных.** То, где хранятся данные, организованные особым образом, иногда в зашифрованном виде.
 - database cluster одна и более БД, управляемые из под одной инстанции сервера
 - Файлы данных кластера лежат в директории data (часто называемой PGDATA)
 - Для каждой БД есть своя подпапка в PGDATA/base
 - Для каждой таблицы и индекса выделяется отдельный файл.

- Таблица состоит из массива страниц (блоков, размером 8кб)
- Файл таблицы называется Heap File содержат списки неупорядоченных записей различной длины



- Таблица размером 1 ГБ
- Состоит из страниц по 8 КБ
- Каждая из которых содержит: заголовок страницы, строки с их заголовками
- Страница содержит ссылки на строки (СТІD)
- Рядом с файлом таблицы лежит файл FSM (free space map)
- FSM не обновляется при каждом обновлении или удалении строк
- VACUUM [FULL] команда для очистки «дохлых» версий строк
- Рядом с файлом таблицы лежит файл VM (visibility map)

Vacuum:

- Если вообще не обслуживать БД, то фрагментация данных будет нарастать
- VACUUM команда для очистки «дохлых» версий строк
- VACUUM FULL полный «компактинг» таблицы
- Необходим периодический запуск VACUUM
- Активно обновляемым БД рекомендуется проходить VACUUM каждую ночь
- VACUUM FULL только если удалили много данных
- VACUUM ANALYZE комбинация двух операций

Индексы:

Индекс - структура данных, ускоряющая выборку данных из таблицы за счет дополнительных операций записи и пространства на диске, используемых для хранения структуры данных и поддержания ее в актуальном состоянии.

Преимущества:

- Позволяет искать значения без полного перебора
- Оптимизация выборки «небольшого» числа записей
- «Небольшое» число число относительное кол-ва записей
- По PRIMARY KEY и UNIQUE столбцам индекс создаётся автоматически
- Индексы не бесплатны

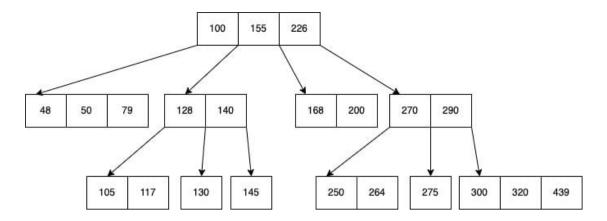
SELECT amname FROM pg_am;

- В-tree (сбалансированное дерево)
- Хеш-индекс
- GiST (обобщённое дерево поиска)
- GIN (обобщённый обратный)
- SP-GiST (GiST с двоичным разбиением пространства)
- BRIN (блочно-диапазонный)

1.B-TREE:

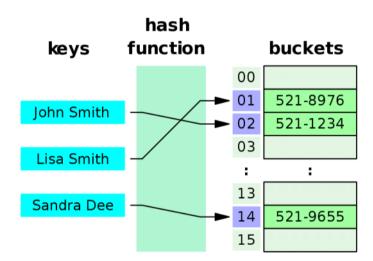
- Создаётся по умолчанию (CREATE INDEX index_name ON table_name (column_name))
- Поддерживает операции:

- Поддерживает LIKE 'abc%' (но не '%abc')
- Индексирует NULL
- Сложность поиска O(logN)



2.HASH:

- CREATE INDEX index_name ON table_name USING HASH (column_name);
- Поддерживает только операцию "="
- Не отражается в журнале предзаписи (WAL)
- Не рекомендуется к применению (в общем и целом)
- Сложность поиска O(1)



Методы Сканирования данных:

- Индексное (index scan)
- Исключительно индексное сканирование (index only scan)
- Сканирование по битовой карте (bitmap scan)
- Последовательное сканирование (sequential scan)

EXPLAIN

- Если есть проблема с производительностью надо понять откуда «растут ноги»
- EXPLAIN query позволяет посмотреть на план выполнения запроса
- EXPLAIN ANALYZE query прогоняет запрос, показывает план и реальность

ANALYZE

- Собирает статистику по данным таблицы
- Планировщик смотрит на статистику при построении плана
- ANALYZE [table_name [(column1, column2...)]]
- Запускать как минимум один раз в день
- autovacuum (если включен) в том числе запускает ANALYZE